

Capítulo 13

Reconhecimento de Entidades Nomeadas no Domínio Legal

Um Panorama para a Língua Portuguesa

Ellen Souza
Hidemberg O. Albuquerque
Nádia F. F. Silva
Matheus Cerqueira
Rafael O. Nunes
André C. P. L. F. de Carvalho
Adriano L. I. Oliveira

Publicado em: 20/11/2024

Atualizado em: 16/04/2026

 <https://brasileiraspln.ufscar.br/livro-pln-4ed-vol3/>

13.1 Introdução

Neste capítulo, são apresentadas as principais iniciativas na área de reconhecimento de entidades nomeadas no domínio legal, com foco na língua portuguesa. São descritos os principais *corpora*, modelos de linguagem neurais e de larga escala, além de exemplo de aplicação de entidades nomeadas na recuperação de documentos legislativos.

O Capítulo **Extração de Informação** apresenta conceitos relacionados à Extração de Informação (EI), que é, normalmente, dividida em diversas tarefas de interesse, com foco no tipo de informação a ser extraída do texto, entre elas, o Reconhecimento de Entidades Nomeadas (REN), a Extração de Relações (ER) e a Extração de Eventos (EE). Com relação ao REN, são apresentadas informações históricas, conceituação formal, abordagens para rotulação, métricas de avaliação, principais entidades e *corpora*, e estado da arte dos modelos de REN para a língua portuguesa.

O Capítulo **PLN no Direito**, por sua vez, apresenta diferentes aspectos associados ao Processamento de Linguagem Natural (PLN) na esfera jurídica. As tarefas de PLN envolvidas, em geral, são a análise textual e a representação de conteúdos por meio de diferentes técnicas, mas há várias abordagens e estudos voltados para diferentes finalidades. São descritos desafios e perspectivas no âmbito de trabalhos que exploram materiais produzidos em português, considerando somente o cenário do Direito brasileiro. Também, é exemplificada uma aplicação de análise de sentimentos em Direito.

13.2 Contextualização

Nos últimos anos, houve um grande crescimento no uso de técnicas de PLN para a área jurídica, que produz uma grande quantidade de dados no formato de texto (Zhong et



al., 2020). Em várias atividades do meio jurídico, é necessário extrair informações desses textos. No entanto, a crescente quantidade de documentos legais, associada ao tamanho desses documentos, torna muitas vezes impraticável sua análise manual. A Inteligência Artificial (IA), em particular PLN, provê técnicas que podem automatizar a extração de conhecimento de textos. Por conta disso, PLN é cada vez mais utilizada para lidar com a grande quantidade de documentos produzidos pelas organizações legislativas e judiciais. Em muitos países, há um considerável acúmulo de casos jurídicos a serem processados e o número de documentos gerados é enorme (Kapoor et al., 2022). A Câmara dos Deputados brasileira, desde sua fundação, já processou mais de 144 mil projetos de lei e tem processado aproximadamente 30 mil projetos de lei a cada ano (Brandt, 2020). Para cada projeto, diversos documentos são produzidos e agregados, em diferentes etapas, até sua discussão e votação.

O levantamento anual do Conselho Nacional de Justiça (CNJ) revelou um aumento significativo no número de projetos de IA no Poder Judiciário Brasileiro em 2023¹, como parte do Programa Justiça 4.0. Em comparação com 2022, houve um crescimento de 17% no número de tribunais com projetos de IA. Das 140 soluções tecnológicas mapeadas, 63 já estão em uso ou aptas a serem utilizadas e 46 estão em fase final de desenvolvimento. Já em 2023, 63% dos tribunais participaram no desenvolvimento de soluções baseadas em IA, em um crescimento de 27% em relação à 2022². Os principais motivadores para o uso da IA pelos tribunais incluem o aumento da produtividade, a busca por inovação, a melhoria na qualidade dos serviços e a redução dos custos. Em 2018, em parceria com a Universidade de Brasília (UnB), o Supremo Tribunal Federal (STF) desenvolveu o Victor (Hartmann Peixoto, 2020), uma IA que separa e classifica as peças processuais mais usadas nas atividades do STF e identifica os temas de repercussão geral de maior incidência. Além do projeto Victor, o STF desenvolveu a VitorIA que identifica, no acervo do Tribunal, os processos que tratam do mesmo assunto e os agrupa automaticamente, e a RAFA 2030 (Redes Artificiais Focadas na Agenda 2030), uma IA, lançada em 2022, para apoiar a classificação de processos de acordo com os Objetivos de Desenvolvimento Sustentável da Agenda 2030 da Organização das Nações Unidas³. Em 2026, o CNJ apresentou o Promptus⁴, um repositório nacional para padronização de instruções (*prompts*) de IA no ecossistema da Plataforma Digital do Poder Judiciário, visando aumentar, entre outras, a segurança jurídica na Justiça brasileira.

Em 2019, a Câmara dos Deputados lançou o Ulysses, um conjunto institucional de iniciativas de IA com o propósito de aumentar a transparência, melhorar a relação da Câmara com os cidadãos e apoiar a atividade legislativa com análises complexas (Almeida, 2021). Inicialmente, o Ulysses analisava, classificava e distribuía os pedidos dos parlamentares entre as 22 áreas de conhecimento da Consultoria Legislativa da Câmara. Posteriormente, em parceria com pesquisadores do Instituto de Ciências Matemáticas e de Computação da Universidade de São Paulo (ICMC-USP), novos algoritmos⁵ foram desenvolvidos, permitindo a busca por documentos similares (Albuquerque et al., 2024b; Souza et al., 2021a; Vitório et al., 2022, 2024), análise do posicionamento de cidadãos sobre

¹<https://www.cnj.jus.br/programa-justica-4-0-divulga-resultados-de-pesquisa-sobre-ia-no-judiciario-brasileiro/>

²<www.cnj.jus.br/wp-content/uploads/2025/09/relatorio-entregas-do-programa-justica-4-0-versao-interativa.pdf>

³<https://portal.stf.jus.br>

⁴<https://www.cnj.jus.br/tecnologia-da-informacao-e-comunicacao/justica-4-0/conheca-o-conecta/prompt-us/>

⁵<https://github.com/ulysses-camara>



um projeto de lei em tramitação (Maia et al., 2022; Silva et al., 2021), reconhecimento de entidades relevantes para o domínio legislativo (Albuquerque et al., 2022, 2023a; Costa et al., 2022), além da construção de modelos de linguagem específicos para o domínio legislativo (Garcia et al., 2024a) e um grande *corpus*, o Ulysses Tesemô (Siqueira et al., 2024), composto por mais de 3,5 milhões de arquivos, totalizando 30,7 GiB de texto bruto, coletados de 159 fontes que abrangem dados judiciais, legislativos, acadêmicos, notícias e outros documentos relacionados.

O domínio legal abrange uma grande variedade de textos jurídicos, incluindo legislação, jurisprudência e trabalhos acadêmicos (Maxwell; Schafer, 2008). A natureza dos documentos legais também acrescenta um novo desafio às aplicações de PLN que pode não estar presente em outros domínios, pois esses documentos são, tipicamente, muito longos, desestruturados, contêm ruídos, e são escritos usando jargão e uma linguagem específica do domínio (Kapoor et al., 2022). Há iniciativas em várias tarefas de PLN e IA, como: Recuperação de Informação Legal (Chalkidis et al., 2021; Souza et al., 2021a), Sumarização de Texto (Kornilova; Eidelman, 2019), Previsão de Julgamentos (Chalkidis et al., 2019), Segmentação Semântica (Malik et al., 2021) e Reconhecimento de Entidades Nomeadas (Albuquerque et al., 2022; Alles, 2018; Araujo et al., 2018; Castro, 2019; Costa et al., 2022).

Legal Named Entity Recognition ou reconhecimento de entidades nomeadas no domínio legal (REN-Legal), tem como objetivo detectar e rotular todas as instâncias de entidades nomeadas específicas, juridicamente relevantes, dentro de textos legais (Bonifacio et al., 2020; Cabrera-Diego; Gheewala, 2023; Cardellino et al., 2017). Considerando que os relatórios jurídicos contêm um grande número de termos e terminologias complexas, identificar entidades é um aspecto crucial na organização de informações e conhecimento dentro do domínio. É uma tarefa com grande importância, pois consiste no primeiro passo da análise semântica do texto, com potencial aplicação em diversas tarefas. Contudo, estudos sobre REN-Legal para a língua portuguesa evidenciam que os modelos utilizados para este idioma enfrentam desafios não encontrados para outros idiomas, o que pode ser explicado pelo baixo volume de *corpora*, ferramentas e modelos pré-treinados desenvolvidos para a língua portuguesa (Albuquerque et al., 2023b; Castro, 2019), necessitando de um esforço maior, principalmente no desenvolvimento de recursos e abordagens, como ocorre com a língua inglesa (Pirovani, 2019).

13.3 Iniciativas de REN-Legal

A revisão sistemática apresentada por Firdaus Solihin; Makarim (2021) mapeou 4.798 pesquisas sobre Extração de Informação no domínio legal, entre janeiro de 1990 e dezembro de 2020, extraindo dados de 107 estudos selecionados. Os autores relatam que 53% das pesquisas utilizaram *corpora* compostos de decisões judiciais, 23% de leis ou regulações, 21% utilizaram outros documentos legais, e os demais 4% utilizaram *corpora* abertos pré-existentes. Os estudos mostraram que as pesquisas utilizando REN-Legal tiveram maior destaque (acima de 60 estudos), ressaltando sua importância para a EI.


Para se ter uma ideia do avanço do estado da arte, para a edição deste capítulo foi executada uma pesquisa amostral das publicações sobre REN-Legal utilizando o *Google Scholar*⁶. Foram utilizadas duas *strings* de busca sobre REN, uma sem informação de

⁶A escolha pelo motor de busca foi baseada na sua praticidade, amplitude (e.g., artigos de eventos, revistas e trabalhos acadêmicos), e facilidade de replicação.



domínio, e a outra com o domínio legal⁷. Para nossos propósitos, foram selecionados arbitrariamente os 100 primeiros artigos de cada resultado, filtrados pelo título e pelo resumo, no período de 2010 a 2026⁸. A Figura 13.1 apresenta o resultado amostral do avanço das pesquisas sobre REN-Legal, principalmente a partir de 2017, ressaltando a importância dada a este domínio especialmente entre 2020 e 2024, período em que o número de publicações em REN-Legal se manteve próxima ou superior às demais pesquisas na maior parte dos anos.

Figura 13.1: Amostra da evolução do estado da arte de REN-Legal



Além da natureza global e complexidade documental próprias do domínio, alguns fatores como diferenças culturais, idioma, linguagem, padronização de documentos, entre outros, podem ser determinantes para o sucesso das aplicações desenvolvidas. Também é preciso considerar seus subdomínios jurídicos existentes (e.g., processual, penal, trabalhista, previdenciário etc.), e suas esferas de atuação (e.g., tipos de tribunais, jurisdição etc.) (Akbik et al., 2016; Cabrera-Diego; Gheewala, 2023; Firdaus Solihin; Makarim, 2021). Neste sentido, alguns trabalhos se destacam por sua relevância para as tarefas de REN-Legal.

Dale; Mazur (2007) exploram o uso de aprendizado de máquina supervisionado para desambiguação de entidades em documentos legais, utilizando 13.460 documentos em inglês da Bolsa de Valores Australiana, aplicados na estimação de frequência de conjunções de entidades candidatas. Foram extraídos 16 tipos de entidades utilizando anotação automática, com desambiguações resolvidas manualmente. Dos nove algoritmos de aprendizagem avaliados, o classificador IBk⁹ (baseado no algoritmo *K-nearest neighbors* (KNN) (Aha et al., 1991)) obteve o melhor resultado, com 84% de medida F1.

Dozier et al. (2010) utilizaram REN para identificação de informações legais em 43.936 documentos de processos legais norte-americanos. Os documentos foram anotados manualmente utilizando cinco entidades legais, classificadas através de abordagens híbridas baseadas em pesquisa (utilizando listas de entidades de interesse), regras contextuais (com regras dedutivas) e modelos estatísticos (com indicadores ponderados). O classificador *Support Vector Machine* (SVM) (Cortes; Vapnik, 1995) obteve o melhor resultado com 95% de medida F1.

⁷Dado que a maioria dos trabalhos sobre REN são escritos em inglês, foram utilizados os termos neste idioma: “*named entity recognition*” e (“*named entity recognition*”+*legal*), respectivamente.

⁸Pesquisas executadas em 24/07/2024, e atualizadas em 28/03/2026 sem o uso de filtros da ferramenta. Para 2026, os resultados representam apenas as publicações recuperadas até março deste ano.

⁹<https://weka.sourceforge.io/doc.stable-3-8/weka/classifiers/lazy/IBk.html>



Chalkidis et al. (2017) exploram a automação da extração de elementos contratuais, construindo um *corpus* de ~3.500 contratos em inglês, manualmente anotados com 11 entidades, das quais três são do domínio legal. Utilizando regras manuais e classificadores lineares como Regressão Logística (Tolles; Meurer, 2016) e SVM, os melhores resultados foram alcançados através de um método híbrido de aprendizado de máquina e regras pós-processamento, com medida F1 acima de 84%. Posteriormente, o *corpus* desenvolvido foi utilizado para gerar vetores de palavras utilizando ~750.000 contratos (Chalkidis; Androutsopoulos, 2017), com melhorias utilizando os modelos *Long Short-term Memory* (LSTM) (Hochreiter; Schmidhuber, 1997), *Bidirectional LSTM* (BiLSTM) (Schuster; Paliwal, 1997) e *Conditional Random Field* (CRF) (Lafferty et al., 2001). Os resultados obtidos alcançaram medida F1 de 87% na classificação por *tokens*, e 88% na identificação de elementos nos contratos.

Chalkidis et al. (2020) exploram a adaptação do modelo *Bidirectional Encoder Representations from Transformers* (BERT) (Devlin et al., 2019) para o domínio legal, através de estratégias de pré-treinamento e ajuste fino do modelo em um *corpus* de 354.621 textos legais em inglês, composto por leis, decisões de tribunais e contratos de diversas fontes. Para as tarefas de REN, foram utilizados dados de cerca de 2.000 contratos, chamado de Contracts-NER. As entidades utilizadas foram as mesmas dos trabalhos anteriores dos autores. O estudo conclui que o modelo LEGAL-BERT, especialmente uma versão menor (LEGAL-BERT-small), foi eficaz para tarefas específicas do domínio legal, apresentando desempenho comparável a modelos maiores.

Pilán et al. (2022) apresentam o *corpus* TAB (*Text Anonymization Benchmark*), desenvolvido para a anonimização de dados pessoais utilizando REN. Composto por 1.268 casos judiciais em inglês do Tribunal Europeu dos Direitos Humanos, o *corpus* foi anotado manualmente utilizando oito entidades universais. No processo de anonimização, entidades marcadas como sensíveis foram categorizadas de acordo com informações como crença filosófica, opinião política, entre outras. Juntamente com o *corpus*, a pesquisa introduz três métricas específicas de avaliação de anonimização: identificadores diretos, identificadores quase-indiretos, e identificadores diretos e quase-indiretos. Um modelo BERT ajustado ao *corpus* alcançou o resultado de 99,9% de revocação para identificadores diretos.

Aejas et al. (2023) apresentam um método para automação de contratos escritos em linguagem natural no contexto de cadeia de suprimentos, utilizando *blockchain*, REN e ER. Foram utilizados 200 contratos públicos em inglês, anotados manualmente com nove entidades do domínio. Os experimentos foram executados com modelos de *deep learning* na avaliação do *corpus* e na criação de um meta-modelo comum para as diferentes estruturas de REN e ER, utilizadas na representação de regras de negócio padronizadas. A acurácia encontrada nestes modelos foi de 99,4% e 99,6%, utilizando BERT e BiLSTM, respectivamente.

Pesquisas relevantes sobre REN-Legal também foram executadas em outras línguas, além da língua inglesa. Na língua alemã, Leitner et al. (2019) apresentam uma metodologia detalhada para REN em documentos legais, com 19 classes de entidades semânticas específicas, generalizadas em sete tipos de classes, que foram avaliados utilizando os modelos CRF e BiLSTM. Mais recentemente, Darji et al. (2023) adapta o modelo GermanBERT para o domínio legal, utilizando as mesmas entidades (Leitner et al., 2019), com resultados melhores que os modelos originais em 14 tipos de entidades específicas. No grego, Angelidis et al. (2018) combinam os modelos BiLSTM, CRF e Regressão Logística para REN em um *corpus* governamental, utilizando seis tipos de entidades. A pesquisa desenvolveu um vocabulário de referências para integrar dados legais com outras fontes na internet,

criando assim uma rede de informações legais acessíveis. Na língua chinesa, Chen et al. (2020) desenvolveram um sistema de extração de entidades e suas relações semânticas em documentos criminais relacionados a drogas, utilizando os modelos RoBERTa (Liu et al., 2019c), BiLSTM e a técnica Seq2Seq (Sutskever et al., 2014). A pesquisa de Çetindağ et al. (2022) apresenta o primeiro estudo sobre REN-Legal para o idioma turco. Foi utilizado um *corpus* de casos de tribunais com oito tipos de entidades (04 universais e 04 legais), os modelos BiLSTM e CRF, além de seis diferentes combinações de vetores de palavras. Na língua espanhola, Samy (2021) apresenta uma metodologia para anotação de entidades em textos legais escritos em espanhol peninsular, utilizando uma abordagem híbrida com expressões regulares, listas de fontes externas e ferramentas para REN. Cinco tipos de entidades foram utilizadas.

O REN também foi explorado em outros idiomas, como árabe (Shamma et al., 2020), finlandês (Oksanen et al., 2019a, 2022), francês (Andrew; Tannier, 2018; Barriere; Fouret, 2019; Sleimi et al., 2021), holandês (Heusden et al., 2023; Schraagen et al., 2017), italiano (Agnoloni et al., 2022; Lorè et al., 2023), romeno (Pais et al., 2021, 2024), além dos idiomas russo (Averina et al., 2022), urdu (Iftikhar et al., 2019), vietnamita (Bach et al., 2019), japonês (Onaga et al., 2023), entre outros, incluindo abordagens multilíngues (Kulkarni et al., 2023; Moreno Schneider et al., 2022; Quaresma; Gonçalves, 2010).

13.4 Iniciativas de REN-Legal em língua portuguesa

Albuquerque et al. (2023b) realizaram um mapeamento das técnicas, métodos e recursos de REN para a língua portuguesa. Foram realizadas buscas manual e automática no período de janeiro de 2010 a junho de 2022, recuperando 447 estudos primários, com 45 estudos incluídos na revisão. Os autores observaram um crescente interesse no desenvolvimento de pesquisas em REN a partir de 2019. Vinte e um estudos primários focaram na análise comparativa entre técnicas e ferramentas, tendo o modelo BiLSTM como o mais utilizado, seguido por métodos mais tradicionais que utilizam apenas CRF. Trabalhos mais recentes utilizaram o modelo BERT. Além disso, 24 estudos descreviam *corpora* de REN para vários domínios, entre eles o legal, com 8 estudos primários mapeados. A Figura 13.2 apresenta a evolução de trabalhos mapeados¹⁰, agrupados de acordo com a variante da língua portuguesa, sendo PT-EU para textos escritos exclusivamente com a variante Europeia e PT-BR com a variante Brasileira.


13.4.1 *Corpora* para REN-Legal

Esforços para a criação e compartilhamento de recursos, como *corpora/datasets* e modelos, vêm sendo feitos pela comunidade de PLN e EI (Firdaus Solihin; Makarim, 2021; Oksanen et al., 2019b). Estes recursos tornam-se cruciais para impulsionar novas pesquisas e o aprimoramento de pesquisas em curso (Bonifacio et al., 2020; Bordino et al., 2021). O Quadro 13.1 apresenta informações sobre alguns *corpora* para REN-Legal em língua portuguesa encontrados na literatura, destacadas a seguir.

¹⁰Segundo a pesquisa, o baixo número de pesquisas no ano de 2022 é justificado pelo período de execução do mapeamento, finalizado em junho de 2022.



Figura 13.2: Distribuição temporal dos artigos mapeados de REN para a língua portuguesa, entre janeiro/2010 e junho/2022 (Albuquerque et al., 2023b)

Quadro 13.1: *Corpora* REN-Legais em língua portuguesa com acesso público (PB) ou privado (PV)

<i>Corpora</i> / (Autores)	Entidades	#Docs/Anotação	Arquitetura	Acesso
LeNER-Br / Araujo et al. (2018)	Legislação, Local, Jurisprudência, Organização, Pessoa, Tempo	70 / manual	BiLSTM, CRF, Glove	PB ¹¹
DOU-corpus / Alles (2018)	Cargo, Data, Evento, Lei, Lugar, Número, Organização, Pessoa, Processo, Valor-monetário	470 / híbrida	OpenNLP	PV
Castro (2019)	Fundamento, Função, Local, Organização, Pessoa, Tribunal, Valor_Acordo, Valor_Causa, Valor_Condenação, Valor_Custas, Vara	1.305 / híbrida	Elmo, GloVe	PV
DrugSeizures-Br / Bonifacio et al. (2020)	Droga, Local, Pessoa, Organização, Outro, Tempo	6.218 / automática	BERT, ELMo	PV
Bonifacio (2020)	DecMorDm, IncMorDm, InitIntArr, InitMon, ValLegFee, ValMorDm	3.022 / manual	BiLSTM, BIGRU, CRF	PV
KauaneJunior / Fernandes et al. (2020b)	Local, Organização, Pessoa	63.380 / automática	CRF, L-BFGS	PB ¹²
Fernandes et al. (2020a)	Pessoa	10.000 / manual	NLTK	PB ¹³
Rodríguez; Bezerra (2020)	Ato, Nome_Ato, Classe, Cod_Matricula_Ato, Empresa_Ato, Fund_Legal, Cargo, Quadro, Padrão, Processo	5.515 sentenças / híbrido	CNN, LSTM, CRF, GloVe	PB ¹⁴
Aposentadoria / Neto; Faleiros (2021)	CPF_CNPJ, Estado_civil, Nacionalidade, Nome, OAB, RG	7.966 / híbrida	BiLSTM, CRF, Glove, Flair	PV
Batista et al. (2021)	Jurisprudência, Legislação	74 / manual	BiLSTM, CRF, Flair, Spacy	PV
Mota et al. (2021)	Citação acadêmica, Precedente, Pessoa, Referência legislativa	594 / manual	BiLSTM, CRF	PV
Correia et al. (2022)	Aditamento Contratual, Aviso de Licitação, Aviso de Revogação/Anulação de Licitação, Aviso de Suspensão de Licitação, Extrato de Contrato, Extrato de Convênio	3.850 / manual	CRF, CNN, LSTM, Word2Vec	PB ¹⁵
Lima; Borges (2022)				

UlyssesNER-Br / Albuquerque et al. (2022), Costa et al. (2023)	Data, Evento, Fundamento, Local, Organização, Pessoa, Produto de Lei	950 + 1000 comentários / manual	BERT, BiLSTM, CRF, Glove	PB ¹⁶ (PL e C-corpus)
CDJUR-BR / Brito et al. (2023)	Endereço, Norma, Pena, Pessoa, Prova, Sentença	1.216 / manual	BERT, BiLSTM, CRF, Spacy	PB ¹⁷
PersoSEG / Guimarães et al. (2024)	Obs.: iniciam com “Ato” Abono_Permanencia, Cessao, Exoneracao_Comissionado, Exoneracao_Efetivo, Nomeacao_Comissionado, Nomeacao_Efetivo, Retificacao_Comissionado, Retificacao_Efetivo, Reversao, Substituicao, Tornado_Sem_Efeito_Apo, Tornado_Sem_Efeito_Exo_Nom	127 / manual	CNN, CRF, LSTM	PB ¹⁸
UlyssesLegalNER-Br / Albuquerque et al. (2026)	Data, Evento, Fundamento, Jurisprudência, Local, Organização, Pessoa, Produto de Lei, Valor Monetário	560 / híbrida	BERT, BiLSTM, CRF, Glove	PB ¹⁹

O *corpus* LeNER-Br (Araujo et al., 2018) é composto por 70 documentos anotados manualmente para a tarefa de REN, sendo 66 provenientes de tribunais judiciais brasileiros, tais como: STF, Superior Tribunal de Justiça, Tribunal de Justiça de Minas Gerais e Tribunal de Contas da União. Outros quatro documentos são legislativos, como a Lei Maria da Penha. Além das entidades Pessoa, Local, Tempo e Organização, o *corpus* contém etiquetas específicas para as entidades Legislação, específica para leis, e Jurisprudência, para decisões relacionadas a casos legais. Um modelo BiLSTM-CRF (Lample et al., 2016) com arquitetura Glove (Pennington et al., 2014) foi retreinado com o *corpus*, alcançando as medidas F1 de 97,04%, 88,82% e 92,53% para entidade Legislação, para Jurisprudência e para todas as entidades, respectivamente.

O DOU-Corpus (Alles, 2018) contém entidades existentes nos documentos do Diário Oficial da União (DOU), um boletim oficial do Governo Federal brasileiro. Para o domínio, foram definidas novas entidades como Cargo, Lei, Número, Organização, Processo e Valor-monetário. A entidade Lei é definida pelos seguintes exemplos: Lei n 5548/97 e LEI 1865/89. A entidade Número descreve todo numerário explorado nos textos do DOU. A entidade Processo contém uma expressão que possui a palavra “processo” com um sequencial de números de um certa formatação. O *corpus* é composto por 60 mil trechos extraídos de diários dos meses de agosto de 2015 à outubro de 2017, anotados utilizando um processo de anotação híbrida (manual e automática). As diferentes seções que compõem o diário foram avaliadas individualmente, alcançando medida F1 de 44,50% com a ferramenta OpenNLP²⁰.

O *corpus* da Justiça Trabalhista (Castro, 2019) é composto por 1.305 documentos obtidos do Processo judicial eletrônico (PJ-e), distribuídos entre atas de audiência, sentenças e acórdãos, e selecionados a partir de processos distribuídos em todas as 24 regiões da justiça do trabalho brasileira, entre os anos de 2008 e 2018. Utilizando uma abordagem de anotação

¹⁹<https://github.com/peluz/lener-br>

¹⁹<https://journals.sagepub.com/doi/10.1177/0010414019858964#supplementary-materials>

¹⁹https://github.com/marciamrodriguez/AtosAdministrativos_RodriguezMarcia2018

¹⁹<https://avio11.github.io/resources/aposentadoria/aposentadoria.html>

¹⁹<https://github.com/alice7lima/PLN/tree/main/Projeto>

¹⁹<https://github.com/ulysses-camara/ulysses-ner-br>

¹⁹<https://github.com/mauriciobritojr/CDJUR-BR>

¹⁹<https://github.com/UnB-KnEDLe/persoseg-corpus>

¹⁹<https://github.com/ulysses-camara/ulysses-ner-br>

²⁰<https://opennlp.apache.org/>



híbrida, foram anotadas as entidades Função, Fundamento, Local, Organização, Pessoa, Tribunal, Vara e Valores (Acordo, Causa, Condenação e Custas). A categoria Função corresponde ao papel das pessoas mencionadas nos documentos, tais como advogado, juiz, reclamado, entre outras funções. Fundamento refere-se a qualquer dispositivo jurídico que possa ser referenciado no documento. Tribunal e Vara visam a identificação de um órgão específico. Foi treinado um modelo de REN-Legal para a Justiça do Trabalho do Brasil, alcançando a medida F1 de 93,81%, utilizando as arquiteturas ELMo (Peters et al., 2018) e GloVe.

A pesquisa desenvolvida por Fernandes et al. (2020a) analisa o impacto de discursos legislativos na captação de votos em sistemas eleitorais portugueses por localidade. Foi utilizado um *corpus* composto por 60.000 discursos parlamentares escritos em português europeu, no período de 1999 a 2015. REN-Legal foi utilizada na análise dos discursos, identificando as entidades Local, Organização e Pessoa, que serviram para medir a frequência e o contexto em que os parlamentares mencionavam seus distritos eleitorais ou outros locais relevantes. Foi utilizado o modelo CRF para identificação automática de entidades, ajustado com o algoritmo *Limited-memory Broyden-Fletcher-Goldfarb-Shanno* (L-BFGS) (Malouf, 2002), a partir de dados sequenciais anotados manualmente. Além disso, para resolver ambiguidades de entidades geográficas, foi utilizada a técnica de Resolução de Topônimos com um dicionário de localidades e regras heurísticas. Para fundamentar a hipótese da pesquisa, foi utilizada uma avaliação qualitativa baseada em entrevistas. Os resultados indicaram que o localismo nos discursos é mais presente conforme a necessidade eleitoral, independente da magnitude do distrito eleitoral, e que, quanto maior o número de candidatos por distrito, maior a quantidade de localismo presente nos discursos.

DrugSeizures-Br (Bonifacio et al., 2020) é um *corpus* contendo 6.218 petições relacionadas a procedimentos de apreensão de drogas. Estas petições foram produzidas pelo Ministério Público do Estado de Mato Grosso do Sul (MPMS) entre os anos de 2015 e 2019. O *corpus* inclui uma tabela de metadados relacionados às petições que compreendem entidades de interesse do MPMS. As entidades anotadas estão divididas em 25 tipos diferentes envolvendo, por exemplo, nome e quantidade da droga apreendida, dados da pessoa denunciada (nome, documentos etc.), local da apreensão, entre outros. Os tipos estão agrupados em 6 categorias: Local, Pessoa, Tempo, Organização, Droga e Outro. Para anotação, foi aplicado um algoritmo simples de busca de *string*: a partir de uma entidade atrelada a uma denúncia, o algoritmo busca a *string* da entidade no texto da denúncia. O *corpus* foi avaliado utilizando a medida F1, com os modelos BERT Multilingual e BERT Acórdãos, alcançando 73,83% e 72,78%, respectivamente, utilizando todas as categorias. Considerando um cenário seletivo, no qual a categoria Outros foi removida do *corpus*, os modelos alcançaram medida F1 de 80,94% e 81,04%.

O *corpus* KauaneJunior (Fernandes et al., 2020b) é composto por 3.022 decisões judiciais sobre a matéria “negativação indevida”, do Tribunal de Justiça do Estado do Rio de Janeiro no ano de 2016. Os documentos foram anotados manualmente, utilizando diretrizes específicas de anotação baseadas em exemplos. Foram utilizados seis tipos de entidades legais: três relacionadas à definição de valor, aumento ou diminuição do dano moral (ValMorDm, IncMorDm e DecMorDm, respectivamente), uma para valor de honorários advocatícios (ValLegFee), além de duas entidades relacionadas a prazos iniciais, tanto para correção monetária (InitIntArr), como para juros de mora (InitMon). Foram utilizados cinco modelos de aprendizagem na avaliação da tarefa: *Bidirectional Gated Recurrent Units network* (BiGRU) (Graves et al., 2013), BiLSTM, CRF, e duas combinações destes modelos. Tanto na análise por entidades quanto no resultado geral, o modelo BiLSTM-CRF obteve



o melhor desempenho, alcançado a medida F1 de 94,79%.

O *corpus* Aposentadoria (Neto; Faleiros, 2021) contém entidades nomeadas de 10 classes associadas a atos de aposentadoria de servidores públicos do Diário Oficial do Distrito Federal (DODF), validadas pelo Tribunal de Contas do Distrito Federal e Territórios. O *corpus* faz parte de um grande conjunto de dados criado por colaboradores do projeto *KnEDLe*²¹ da Universidade de Brasília. As entidades mapeadas foram Ato, Nome_Ato, Classe, Cod_Matricula_Ato, Empresa_Ato, Fund_Legal, Cargo, Quadro, Padrão, Processo e estão anotadas no formato CoNLL-2003 (Sang; De Meulder, 2003). A divisão entre treinamento, validação e teste foi feita em ordem cronológica dos DODFs, para não dividir entidades do mesmo documento do DODF em diferentes conjuntos. O conjunto de treinamento foi formado por 3.860 sentenças, o de validação por 828 sentenças e o de teste por 827 sentenças.

O *corpus* UlyssesNER-Br (Albuquerque et al., 2022) é composto por 150 projetos de lei (PL-corpus) e 800 consultas legislativas (ST-corpus) da Câmara dos Deputados brasileira. Anotados manualmente em três fases e por três grupos de anotadores, o *corpus* possui sete categorias semânticas, algumas contendo tipos específicos. A avaliação da concordância entre anotadores alcançou coeficiente Kappa de 91% na média. Além de cinco categorias baseadas no HAREM (Santos; Cardoso, 2007b), Pessoa, Localização, Organização, Evento e Data, o *corpus* possui duas categorias específicas para o domínio legislativo: Fundamento e Produto de Lei. Fundamento refere-se a entidades relacionadas a leis (FUNDlei e FUNDapelido), resoluções, decretos, bem como a entidades específicas do domínio, como projetos de lei (FUNDprojetodelei), que são propostas de lei em discussão pelo parlamento, e consultas legislativas (FUNDSolicitacaotrabalho), realizadas pelos parlamentares. Produto de Lei refere-se a sistemas (PRODUTOsistema), programas (PRODUTOprograma) e outros produtos (PRODUTOoutros) criados a partir da legislação. O *corpus* foi avaliado com os modelos HMM e CRF, obtendo melhor resultado com o CRF, alcançando a medida F1 de 81,04%.

Posteriormente, o *corpus* UlyssesNER-Br foi expandindo com texto informal gerado pelo usuário (Costa et al., 2022). Para a expansão, foram utilizados, aproximadamente, 1000 comentários públicos de cidadãos (C-corpus), relacionados a projetos de lei em tramitação, coletados de enquetes do portal da Câmara dos Deputados. Foram anotadas manualmente as mesmas entidades da primeira versão (Albuquerque et al., 2022), com exceção da FUNDSolicitacaotrabalho, a qual só está presente nos documentos de consultas legislativas. O coeficiente de anotação Kappa alcançou a média de ~80%. O modelo BERT com ajuste fino, treinado com a junção do C-corpus e PL-corpus, melhorou o resultado individual do treinamento para C-corpus, alcançando medida F1 de 73,90%.

Correia et al. (2022) disponibilizaram um *corpus* anotado manualmente para REN em português no contexto do Judiciário brasileiro. O *corpus* contém 594 decisões publicadas pelo STF e anotadas por 76 estudantes de Direito. O processo de anotação foi composto por três fases, duas de treinamento e uma fase final. Os autores utilizaram um processo de anotação detalhada de decisões jurídicas, na qual foram anotados dois níveis de entidades jurídicas aninhadas. No primeiro nível, foram anotadas quatro entidades mais abrangentes (categorias): Precedente, Citação acadêmica, Referência legislativa e Pessoa. No segundo nível, foram anotadas entidades específicas de cada uma das quatro categorias. No total, foram identificadas 24 entidades aninhadas (tipos). Dois grupos de estudantes, ao longo de quase um ano, realizaram a tarefa de anotação sob rigorosa supervisão. Ambos os grupos

²¹<https://unb-knedle.github.io/>



realizaram anotação na mesma coleção de 1.363 trechos, com um coeficiente de concordância Kappa médio de 70%. Os modelos CRF e BiLSTM-CRF construídos obtiveram a mesma medida F1 de 90%.

O artigo de Brito et al. (2023) apresenta uma metodologia de anotação manual de documentos jurídicos que serviu como base para construção do CDJUR-BR, um *corpus* de REN-Legal com 1.216 documentos de processos judiciais brasileiros, contendo 21 entidades específicas das categorias Pessoa, Prova, Pena, Endereço, Sentença e Norma. Um comitê com professores da área do Direito e da Computação, juntamente com os especialistas do domínio, definiu os principais parâmetros do CDJUR-BR, bem como garantiu a adequada aplicação da metodologia. Foram selecionados documentos das classes-CNJ mais representativas dos processos de primeiro grau, encerrados em 2019 no Tribunal de Justiça do Estado do Ceará (85% dos processos de primeiro grau são das classes selecionadas). O processo de anotação foi realizado em duas fases, sendo a primeira de treinamento. Foram definidos três grupos de anotadores formados por especialista. A avaliação da concordância alcançou coeficiente Kappa de 0,69 para 73% dos documentos, e os demais documentos passaram por revisões por especialistas e etapas de refinamento. Com a CDJUR-BR, os resultados apontaram superioridade do modelo BERT com medida F1 média de 58%. Testes comparativos entre CDJUR-BR e LeNER-BR indicaram que o modelo REN treinado com a CDJUR-BR é superior em reconhecer entidades de outros *corpora*.

O *corpus* PersoSEG (Guimarães et al., 2024) é composto por 127 documentos legais em português, no período de 2001 a 2015, obtidos do DODF. A pesquisa utiliza técnicas de REN aplicadas às tarefas de segmentação e rotulação em documentos legais. Foram utilizadas 12 tipos de entidades manualmente anotadas, representando atos da administração pública, como por exemplo, abono de permanência, (Ato_Abono_Permanencia), nomeação ou exoneração de cargos comissionados (Ato_Nomeacao_Comissionado e Ato_Exoneracao_Comissionado) ou efetivos (Ato_Nomeacao_Efetivo e Ato_Exoneracao_Efetivo), entre outras. O *corpus* foi avaliado utilizando combinações dos modelos CRF, CNN e LSTM, com melhor medida F1 média de 75,65% para REN com o modelo CRF.

A pesquisa desenvolvida por Albuquerque et al. (2026) estende o *corpus* UlyssesNER-Br originalmente voltado para o domínio legislativo, para um *corpus* jurídico mais abrangente, unificado e de dados abertos, cobrindo três subdomínios: projetos de lei, jurisprudência e leis. O *corpus* UlyssesLegalNER-Br é composto por 560 documentos públicos, anotados por meio de uma abordagem híbrida, que combina sugestões automáticas com curadoria humana especializada. Com o objetivo de preservar a compatibilidade com a versão anterior, os autores utilizaram as entidades do UlyssesNER-Br, e acrescentaram duas novas categorias, Jurisprudência e Valor Monetário, totalizando 9 categorias semânticas e 23 tipos específicos. A pesquisa revisou sistematicamente as anotações anteriores a partir da versão original do PL-corpus (público), atualizando o esquema de anotação, corrigindo inconsistências e incorporando as novas entidades. O *corpus* ampliado passou então a ser formado por três *subcorpora*: o PL-corpus_v3, voltado para o domínio legislativo, ampliado para 300 documentos e com cobertura temática mais ampla, incluindo textos do Senado Federal; o Juris-corpus, com 160 decisões de diferentes cortes superiores e órgãos do sistema jurídico brasileiro; e o Leis-corpus, o primeiro *corpus* de REN composto exclusivamente por leis brasileiras, num total de 100 documentos, contendo, entre outros, a Constituição Federal de 1988, três constituições estaduais, além de outros códigos. Os *corpora* foram avaliados utilizando um protocolo experimental sistemático, tanto individualmente como de forma unificada, com modelos de aprendizado de máquina consolidados no estado da arte (CRF, BiLSTM, Glove, BERTimbau). O estudo incluiu ainda uma análise complementar de



eficiência computacional destes modelos. O BERTimbau apresentou os melhores resultados em todos os *corpora*, alcançando a maior medida F1 de 96,18% no *corpus* unificado. A análise dos resultados também permitiu observar como diferentes arquiteturas se comportam em *corpora* jurídicos distintos, reforçando o papel do *corpus* desenvolvido como um recurso multigênero que reduz a fragmentação de *corpora* jurídicos em português, oferecendo uma base consistente para estudos futuros em diferentes granularidades e tipos documentais. Todos os recursos do projeto (dados e modelos) foram publicados abertamente.

13.4.2 Modelos de linguagem neurais para REN-Legal

O Capítulo [Modelos de linguagem](#) descreve os conceitos relacionados aos modelos de linguagem, detalhando o funcionamento dos modelos probabilísticos, neurais e de grande escala (*Large Language Models* ou LLMs). Nesta subseção, são apresentados estudos e modelos neurais específicos para o REN-Legal em língua portuguesa.

A pesquisa de Bonifacio et al. (2020) avalia o uso de modelos de linguagem neural para as tarefas de REN-Legal, utilizando os modelos pré-treinados para a língua portuguesa ELMo e BERT, ajustados para o domínio legal. Os ajustes foram feitos utilizando o *corpus* Acordãos-TCU, composto de 298 mil documentos do Tribunal de Contas da União (TCU)²². Os modelos foram avaliados em diferentes cenários, utilizando os *corpora* HAREM, LeNER-Br e DrugSeizures-Br. Os resultados demonstraram que os modelos treinados no domínio foram melhores. O modelo BERT obteve o melhor desempenho, alcançando a medida F1 de 89,39%, superando o LeNER-Br em cerca de quatro pontos na média.

O trabalho de Zanuz; Rigo (2022) apresenta os primeiros modelos BERT ajustados para REN-Legal em língua portuguesa. Dois modelos pré-treinados, *bert-base-portuguese-cased* e *bert-large-portuguese-cased*, foram utilizados no treinamento. O ajuste fino foi realizado com 10 épocas sobre os dados de treinamento e o melhor modelo, considerando a medida F1, foi selecionado para avaliar os resultados no conjunto de teste. Os modelos propostos foram comparados com resultados anteriormente obtidos para o *corpus*: LSTM+CRF, BERT-Multi, BERT-Acordaos e ELMo-Acordaos. Para o *corpus* LeNER-Br, os modelos BERT pré-treinados para língua portuguesa (Souza et al., 2020a) ajustados para o domínio alcançaram medida F1 de 91,14% no BERTimbau-Large e 90,62% no BERTimbau-Base.

O estudo de Albuquerque et al. (2023a) avaliou duas arquiteturas de *deep learning*, BiLSTM-CRF e BERT+Fine-Tuning, aplicadas a tarefa de REN-Legal em português brasileiro, utilizando os *corpora* UlyssesNER-Br e LeNER-Br. Para o UlyssesNER-Br, foi utilizado o conjunto de documentos que contém apenas projetos de lei (PL-corpus) visto que estes estão disponíveis publicamente. O modelo BERT+Fine-Tuning alcançou resultados superiores, com medida F1 de 88,27% para o LeNER-Br e 83,17% para o UlyssesNER-Br/PL-corpus, com um aumento de cerca de 7% neste último em relação à primeira versão.

O trabalho de Nunes et al. (2024b) explora como o REN pode ser aprimorado usando técnicas semi-supervisionadas. A abordagem consiste em uma estratégia de autoaprendizagem para ajustar um modelo BERT projetado para REN, usando documentos legislativos escritos em português brasileiro como estudo de caso. O UlyssesNER-Br foi utilizado para treinamento e avaliação. O BERTimbau com autoaprendizagem obteve a medida F1 de $86,70 \pm 2,28$.

²²<https://www.kaggle.com/datasets/ferraz/acordaos-tcu>



A pesquisa de Garcia et al. (2024a) investiga a aplicação de métodos de PLN na adaptação de modelos para o domínio legal em língua portuguesa. O modelo RoBERTaLexPT foi desenvolvido aplicando técnicas de deduplicação de dados (identificação e eliminação de cópias duplicadas de dados) ao modelo RoBERTa, utilizando os *corpora* LegalPT (composto de seis *corpora* legais), o *corpus* CrawlPT (composto por três *corpora* do domínio geral) e o Tesemô (Siqueira et al., 2024). Os experimentos incluíram pré-treinamento e *fine-tuning* dos modelos em tarefas de REN-Legal e classificação com *benchmarks*, comparando os resultados dos modelos genéricos com específicos. Os resultados mostraram que o RoBERTaLexPT treinado com a combinação de *corpora* legal e geral, superou outros modelos legais, incluindo o RoBERTaTimbau, alcançando medida F1 média de 90,73% para LeNER-Br e 88,56% UlyssesNER-Br (categoria).

A Tabela 13.1 apresenta os resultados obtidos para a tarefa de REN-legal em língua portuguesa utilizando modelos de linguagem neural. É possível verificar que, a partir de 2020, com o trabalho de Bonifacio et al. (2020), os trabalhos assumiram o estado da arte utilizando o modelo BERT.

Tabela 13.1: Modelos de linguagem neural estado da arte para REN-Legal em português

Corpus	Modelo	Medida F1
Justiça do Trabalho	ELMO+GLOVE (Castro, 2019)	93,81%
DrugSeizures-Br	BERT (Bonifacio et al., 2020)	89,39%
LeNER-Br	BERTimbau-Large+Fine-Tuning (Zanuz; Rigo, 2022)	91,14%
CDJUR-BR	BERT (Brito et al., 2023)	58,00%
UlyssesNER-Br (PL-Corpus)	RoBERTaLexPTbase (Garcia et al., 2024a)	88,56% (categoria)

As avaliações recentes de REN-Legal em português mostram que ganhos de desempenho precisam ser interpretados com cautela, sobretudo quando há risco de contaminação entre treino, validação e teste ou inconsistências de anotação nos *corpora*. Essa preocupação acompanha discussões mais amplas em PLN sobre sensibilidade a particionamentos e estabilidade de métricas (Gorman; Bedrick, 2019; Sainz et al., 2023), e foi evidenciada por Nunes (2025), ao analisar os *corpora* LeNER-Br e UlyssesNER-Br/PL-corpus em um *benchmark* com 22 modelos de diferentes arquiteturas, a partir de um processo de decontaminação que envolveu remoção de sentenças duplicadas entre partições e revisão de anotações parciais e ambíguas. No LeNER-Br, a limpeza reduziu em 11,2% o total de entidades anotadas, enquanto no UlyssesNER-Br/PL-corpus também foram removidas instâncias tanto no nível de categorias quanto no de tipos. Os efeitos foram expressivos: no LeNER-Br, 18 dos 22 modelos apresentaram diferença estatisticamente significativa entre as versões contaminada e decontaminada, com perdas de micro-F1 de até 10,14 pontos; no PL-corpus, as oscilações chegaram a variar de $-17,71$ a $+16,23$ pontos em categorias e de $-10,00$ a $+14,18$ em tipos. Em outras palavras, a contaminação não apenas pode inflar resultados absolutos, mas também modificar a leitura comparativa entre os próprios modelos.

Na versão decontaminada, os melhores resultados de micro-F1 foram obtidos por RoBERTaLexPT-base no LeNER-Br, por Legal-portuguese-R-large no UlyssesNER-Br/PL-corpus em categorias e por Albertina-100m no nível de tipos, o que sugere que o tamanho do modelo, por si só, não explica o desempenho observado. Ao mesmo tempo, a análise de erros mostrou que a REN-Legal continua marcada por dificuldades típicas do domínio



jurídico, como ambiguidades entre classes semanticamente próximas (p. ex., LOCAL e ORGANIZAÇÃO, no LeNER-Br), problemas no reconhecimento de entidades compostas (principalmente em referências legais), e forte sensibilidade à qualidade das anotações (p. ex., PRODUTODELEI, FUNDAMENTO e ORGANIZAÇÃO, no UlyssesNER-Br/PL-corpus). Esse quadro reforça duas implicações metodológicas centrais: a curadoria do *corpus* deve integrar o protocolo experimental desde o início, com deduplicação, revisão de anotações e tratamento de ambiguidades; e a comparação entre modelos não deve se apoiar apenas em médias de medida F1. Nesse sentido, a análise estatística com teste de Wilcoxon pareado e teste de Friedman com pós-teste de Nemenyi indica que pequenas diferenças numéricas nem sempre correspondem a vantagens consistentes, o que torna mais adequada uma avaliação que combine desempenho, robustez estatística e controle rigoroso dos dados.

13.5 Modelos de linguagem de grande escala (LLM) para REN

Conforme descrito na Seção **Tendências**, os LLMs se diferenciam dos demais modelos de linguagem neural pré-treinados devido a (i) quantidade enorme de parâmetros, o (ii) enquadramento na categoria de métodos de IA Gerativa, e (iii) habilidades emergentes, as quais não costumam ser observadas em modelos menores. Neste sentido, destacamos aqui algumas aplicações de LLMs em tarefas de PLN, independente de língua. Por fim, na Subseção **LLM para REN-Legal em língua portuguesa**, detalhamos as iniciativas de REN-Legal em língua portuguesa.

O trabalho de Wang et al. (2021) foi um dos primeiros a investigar como o modelo de linguagem GPT-3 (Brown et al., 2020c) pode ser utilizado como uma ferramenta de rotulagem de dados de baixo custo para treinar outros modelos de PLN. Os autores conduziram um estudo empírico em nove tarefas de PLN, como sumarização, análise de sentimento e classificação de tópico. A pesquisa demonstrou que (i) o uso do GPT-3 para rotulagem de dados pode reduzir os custos de rotulagem em até 96% em comparação com a rotulagem humana, (ii) dados rotulados pelo GPT-3 podem superar o desempenho do próprio GPT-3 em configurações de *few-shot learning*, (iii) a combinação de rótulos gerados pelo GPT-3 com rótulos humanos pode melhorar ainda mais o desempenho dos modelos e, por fim, (iv) a estratégia de rotulagem ativa proposta no artigo, na qual os rótulos de baixa confiança do GPT-3 são revisados por humanos, melhora a qualidade dos dados anotados.

Especificamente para REN, Wang et al. (2023) apresentaram o GPT-NER para adaptar modelos de linguagem de grande escala à tarefa de REN, transformando-a em uma tarefa de geração de texto com *tokens* especiais para entidades. Foi introduzida uma estratégia de auto-verificação para mitigar alucinações do modelo. Foram realizados experimentos em cinco conjuntos de dados de REN para língua inglesa em domínios variados. O GPT-NER alcançou desempenho comparável aos *baselines* supervisionados utilizando *few-shot learning*, superando modelos supervisionados com dados de treinamento escassos. De maneira similar, o trabalho de Wei et al. (2024) apresenta o ChatIE, um framework de extração de informações com *few-shot learning* através de conversas com o ChatGPT²³. O ChatIE foi avaliado em três tarefas de EI, entre elas a tarefa de REN, a qual foi transformada em um problema de pergunta e resposta com duas etapas. Na primeira etapa, são identificados os tipos de elementos em uma sentença. Na segunda etapa, é realizada a EI para cada tipo de elemento identificado. Para a tarefa de REN, foram usados dois conjuntos de dados relacionados a notícias, um em inglês e outro em chinês. O ChatIE

²³<https://chatgpt.com/>



alcançou excelente desempenho, superando alguns modelos em vários conjuntos de dados.

No domínio legal, o trabalho de Hussain; Thomas (2024) investiga a aplicação de modelos de LLM na extração de entidades específicas do domínio jurídico, em documentos de casos legais indianos. O estudo avalia a eficácia de várias arquiteturas de LLMs de última geração na identificação de entidades jurídicas. O conjunto de dados utilizado para avaliação foi o InLegalNER, um *corpus* contendo 14 entidades, sendo 11 entidades específicas do domínio legal, tais como Petição, Vítima, Número do Caso, Juiz, Advogado, entre outras. Foram avaliados quatro modelos de larga escala: LLaMA 3 (AI@Meta, 2024), Gemma (Team et al., 2024), Mistral (Jiang et al., 2023) e Phi-3 (Abdin et al., 2024), utilizando a técnica de *few-shot learning*, na qual o *prompt* foi elaborado instruindo o LLM a gerar respostas em formato JSON, incluindo o texto extraído e os rótulos de entidade correspondentes. Os modelos foram avaliados utilizando precisão, revocação e medida F1 como métricas. O LLaMA 3 alcançou a medida F1 de 59,17%, Gemma de 63,53%, Mistral de 63,76%. Phi-3 de 54,40%. Os principais resultados indicam que os modelos Mistral e Gemma se destacaram em termos de equilíbrio entre precisão e revocação, essenciais para a identificação precisa de entidades.

13.5.1 LLM para REN-Legal em língua portuguesa

Visando encontrar alternativas para os métodos tradicionais de anotação manual, reduzindo os custos e esforços de anotação, o trabalho de Oliveira et al. (2024c) investiga o uso de LLM baseados em *prompt* e supervisão fraca para a tarefa de REN-Legal em português. O estudo utilizou o DODFCorpus I, disponibilizado pelo projeto KnEDLe da Universidade de Brasília. Foi utilizado o *corpus* “Atos de Contratos e Licitações”, que contém documentos públicos diários que relatam as ações do governo do Distrito Federal do Brasil, particionado em 783 atos de treinamento, 379 atos de validação e 380 atos de teste. Foram comparadas três abordagens: (i) baseada em *prompt*, com *few-shot learning*, apresentando três exemplos de dados rotulados ao GPT-3, (ii) supervisão fraca, com sistema baseado em regras e heurísticas para gerar conjuntos de dados rotulados rapidamente e (iii) anotação humana. As 783 instâncias de treinamento foram rotuladas pelo GPT-3, realizando a predição de 1.565.108 *tokens*, com um custo final de 31,30 dólares utilizando o modelo Davinci. Quatro modelos de linguagem neural pré-treinados, com ajuste fino, foram usados para a construção do modelo de REN: BERTimbau, Lener-BR, RoBERTa e DistilBERT-PT²⁴. Para as onze entidades do *corpus*, considerando a média dos quatro modelos e a métrica de medida F1, os resultados foram: 52,8% (GPT-3), 67,9% (supervisão fraca), 71,3% (anotação humana) e 64,6% (GPT-3 + supervisão fraca). Considerando a métrica de pontuação de preservação, que preserva o desempenho apresentado pelos modelos treinados por humanos, os resultados foram: 74,0% (GPT-3), 95,6% (supervisão fraca), 90,7% (GPT-3 + supervisão fraca) e 83,9% (GPT-3 + 30% de anotação humana). O BERTimbau superou o LenerBR em alguns casos, mesmo este último tendo sido adaptado para documentos legislativos brasileiros.

O trabalho de Nunes et al. (2024a) explora a aplicação do paradigma de Aprendizagem em Contexto (em inglês, *In-Context Learning* ou ICL), para melhorar o desempenho dos LLMs para o REN-Legal em língua portuguesa. O Sabiá, um LLM em português (Pires et al., 2023), foi utilizado para extrair entidades nomeadas no domínio. Dois *corpora* de REN para o domínio legal (LeNER-Br e UlyssesNER-Br) foram utilizados como entrada para a tarefa de *prompt*. Para a seleção das amostras, foram utilizadas três heurísticas: (i) top K exemplos similares, (ii) top K exemplos similares por tipo de entidade, e (iii) K amostras

²⁴<https://huggingface.co/adalbertojunior/distilbert-portuguese-cased>



aleatórias. O modelo generativo foi ensinado a catalogar as entidades e o resultado foi comparado com a anotação original. No *corpus* LeNER-Br, a heurística K similares por categorias apresentou medida F1 de 51% com oito exemplos. No resultado por tipos, três classes de entidades superaram 50% de medida F1: Pessoa com 68%, Organização com 53%, e Jurisprudência com 53%. No *corpus* UlyssesNER-Br, a mesma heurística atingiu medida F1 de 48% com oito exemplos, necessitando de onze exemplos para alcançar 51%. No resultado por tipo, três classes também obtiveram mais de 50% de medida F1: Data com 81%, Local com 69%, e Pessoa com 60%. De acordo com os autores, as classificações incorretas são resultados de uma formatação similar de termos que se referem a conceitos diferentes (Jurisprudência e Legislação, por exemplo), ambiguidade semântica (o “jornal diário catarinense” pode ser um Local ou uma Organização) e estruturas e jargões específicos do domínio (Plenário, junto com referências a jurisprudência ou legislação, separadas por um traço, confunde o modelo). A amostragem aleatória apresentou o pior desempenho.

O trabalho de Coelho et al. (2024) aborda a extração de informações no domínio jurídico brasileiro, especificamente extraindo características estruturadas de pareceres jurídicos relacionados a reclamações de consumidores. O estudo compara dois métodos: técnicas tradicionais de aprendizado supervisionado e o uso de LLM, especificamente o ChatGPT, nas tarefas de classificação de texto e de REN. O *corpus* utilizado nos experimentos contém 959 pareceres jurídicos manualmente anotados, redigidos por juízes de primeira instância no Tribunal de Justiça do Rio de Janeiro. As entidades anotadas foram: Dano Moral, Dano Material, Honorários Advocatícios e Restituição. Utilizando a versão GPT-3.5-turbo, a técnica de *prompt* envolveu três principais itens: detalhes das informações a serem extraídas, formato de saída e exemplos opcionais (*few-shot*). Os resultados obtidos foram em termos de acurácia e raiz quadrática média dos erros (em inglês, *Root Mean Squared Errors* ou RMSEs): BERT (*Fine-tuning*) 96,2% e 825,8, BERT-CRF (*Fine-tuning*) 98,2% e 639,8, BERT-LSTM (*Feature-based*) 95,4% e 738,6, BERT-LSTM-CRF (*Feature-based*) 98,9% e 277,2, ChatGPT Entity Extractor 98,4% e 1230,9. Os resultados dos experimentos mostraram que ambas as abordagens (aprendizado supervisionado tradicional e ChatGPT) alcançaram desempenhos semelhantes em termos de métricas de avaliação tradicionais. No entanto, o uso do ChatGPT reduziu substancialmente a complexidade e o tempo necessário para o processo de EI.

A Tabela 13.2 apresenta os resultados obtidos para a tarefa de REN-legal em língua portuguesa utilizando, exclusivamente, LLMs.

Tabela 13.2: LLMs estado da arte para REN-Legal em português.

<i>Corpus</i>	Modelo	Métrica
DODFCorpus I	GPT-3 Davinci + <i>few-shot learning</i> com 3 exemplos (Oliveira et al., 2024c)	52,8% (F1)
LeNER-Br	Sabiá + <i>in-context learning</i> com 8 exemplos (Nunes et al., 2024a)	51,0% (F1)
UlyssesNER-Br	Sabiá + <i>in-context learning</i> com 11 exemplos (Nunes et al., 2024a)	51,0% (F1)
Reclamações de Consumidores	GPT-3.5-turbo + <i>few-shot learning</i> (ChatGPT Entity Extractor) (Coelho et al., 2024)	98,4% (Acurácia)




13.6 Aplicação de REN em sistema de recuperação de informação legislativa

O Capítulo **Recuperação de Informação** destaca a importância da área da Recuperação de Informação (RI) para o PLN. Pesquisas na área de *Legal Information Retrieval* ou recuperação de informação no domínio legal (RI-Legal) focam principalmente em aplicações que utilizam a linguagem judiciária, forense ou processual (Sansone; Sperlí, 2022). O Capítulo **PLN no Direito** destaca que a esfera de aplicação do subdomínio legislativo é a criação de textos legais, como leis e estatutos, entre outros. Sistemas RI-Legal têm sido criados ou adaptados para diversas tarefas legislativas (Heusden et al., 2023; Smywiński-Pohl et al., 2021).

Como mencionado anteriormente, o projeto Ulysses (Seção **Contextualização**) é um conjunto de iniciativas de IA aplicados no processo legislativo brasileiro, criado pela Câmara dos Deputados, o qual recebeu recentemente novos recursos em várias frentes de trabalho²⁵. Entre estes recursos, foi utilizado o *pipeline* para um sistema de RI-Legal proposto por Souza et al. (2021a), visando automatizar tarefas de busca de documentos relevantes. REN-Legal foi inserido neste contexto.

Figura 13.3: *Pipeline* do UlyssesNERQ, adaptado de Albuquerque et al. (2024b)



O UlyssesNERQ (Albuquerque et al., 2024b) atualiza o *pipeline* do sistema de RI-Legal original, utilizando NER-Legal e a técnica de expansão de consulta. Através desta técnica, o sistema de RI modifica a *string* de consulta original, inserindo informações que possam maximizar seus resultados (Seção **Modificação Automática de Consultas**). A Figura 13.3 detalha o processo utilizado. O sistema recebe como entrada a *query* com solicitação de consulta legislativa e o *corpus* UlyssesNER-Br. Após a aplicação de tarefas de pré-processamento de texto na consulta, é feita a identificação de duas entidades legislativas, FUNDprojetoidei e FUNDSolicitacaotrabalho. Em caso de identificação destas entidades, a consulta é expandida com os conteúdos dos documentos correlacionados: (i) para a entidade FUNDprojetoidei, a consulta é expandida com a ementa dos projetos de lei encontrados; (ii) para FUNDSolicitacaotrabalho, a expansão é feita com todo o conteúdo da solicitação legislativa encontrada. Em caso de não ter sido encontrada nenhuma entidade, a consulta não é modificada. O Quadro 13.2 apresenta exemplos fictícios de consultas legislativas, com e sem expansão utilizando entidades. Ao final, são retornados os *top K* documentos mais relevantes encontrados.

²⁵Recursos disponíveis publicamente em <https://github.com/ulysses-camara>

Quadro 13.2: Exemplos de expansão de consultas legislativas utilizando REN, adaptado de (Albuquerque et al., 2024b). Expansões de consulta em negrito.

Consulta legislativa (<i>query</i>)	Entidades encontradas	Consulta expandida
Solicito revisão dos projetos de lei PLP 438/2014 e PLP 137/2015.	PLP 438/2014 PLP 137/2015	Solicito revisão dos projetos de lei PLP 438/2014 e PLP 137/2015. Dispõe sobre o procedimento para a criação, a incorporação, a fusão e o desmembramento de Municípios, nos termos do § 4º do art. 18 da Constituição Federal, altera a Lei nº 5.172, de 25 de outubro de 1966, e dá outras providências. Dispõe sobre o procedimento para a criação, a incorporação, a fusão e o desmembramento de Municípios, nos termos do § 4º do art. 18 da Constituição Federal, e dá outras providências.
Solicito complementação de parecer em função da apensação do PL 5165/2019 ao mesmo.	PL 5165/2019	Solicito complementação de parecer em função da apensação do PL 5165/2019 ao mesmo Altera o art. 3º da Lei n. 13.855, de 8 de julho de 2019, para modificar a sua cláusula de vigência
Parlamentar solicita aprovação	–	Parlamentar solicita aprovação

Para validação do UlyssesNERQ, os experimentos utilizaram 32 configurações de pré-processamento de texto nas *strings* de busca com as técnicas de *stemming*, contagem de frequência, modelos de linguagem *n-gram*, e diversas combinações. A expansão de consulta foi então avaliada aplicando três modelos de REN-Legal ajustados para o domínio: CRF (Albuquerque et al., 2022), BERT (Albuquerque et al., 2023a), e uma adaptação do modelo Bertikal (Polo et al., 2021) ajustado para as entidades legislativas. Além destes modelos, foram utilizadas duas técnicas de expansão de consulta, a primeira utilizando sinônimos, e a segunda utilizando termos relacionados ou representativos ao conteúdo, através do algoritmo RM3 (Nogueira et al., 2019). Os resultados foram verificados isoladamente e através de análises estatísticas. A métrica utilizada foi a medida de Revocação para 20 documentos (Recall@20). O melhor resultado foi alcançado pelo modelo BERT, alcançado 74,58% de revocação na análise individual, e média de $65,19\% \pm 0,0840$, ultrapassando os resultados do *pipeline* original. Este modelo foi novamente combinado com as técnicas utilizadas, alcançando o mesmo resultado individual anterior, mas com média um pouco melhor utilizando a combinação de RM3 + BERT, com $65,35\% \pm 0,0810$ de revocação. Comparando com o resultados do pipeline original, houve uma melhoria de cerca de 1,94% para os melhores resultados, e de 8,58% no resultado geral.

13.7 Considerações finais

Neste capítulo, foram detalhadas as principais iniciativas na área de reconhecimento de entidades nomeadas no domínio legal, com foco na língua portuguesa. Destacou-se o crescimento do uso de técnicas de Processamento de Linguagem Natural nesse campo, especialmente no Brasil. Foram discutidos os desafios inerentes à extração de informações de documentos jurídicos, considerando a grande quantidade e a complexidade desses textos. Além disso, foram mencionadas aplicações relevantes de inteligência artificial nas áreas jurídica e legislativa, como os projetos Victor e Ulysses, respectivamente. Apresentou-se um panorama abrangente das iniciativas em diversas línguas relacionadas ao REN no domínio legal, com suas abordagens e métodos, como aprendizado supervisionado e modelos neurais. Foram descritos *corpora* importantes para o REN-Legal em língua portuguesa e avaliação de modelos treinados especificamente para esse domínio, destacando seu desempenho em *corpora* brasileiros. Por fim, explorou-se a aplicação de REN em sistemas de recuperação de informação legislativa, como o UlyssesNERQ, que aprimora as consultas por meio da



identificação de entidades nomeadas, aumentando a eficiência na busca de documentos relevantes.

No campo de pesquisa sobre REN, diversas áreas têm se destacado com foco na melhoria contínua dos modelos. Investigações com LLMs têm se mostrado promissoras, permitindo avanços no processamento de grandes volumes de dados e na adaptação a tarefas específicas. Contudo, o desbalanceamento entre classes de entidades, no qual certas categorias apresentam uma representação desproporcionalmente menor nos dados, continua sendo um desafio. Esse fenômeno, aliado à existência de entidades pouco representativas, podem impactar negativamente o desempenho dos modelos. Estratégias como *Data augmentation*, que visa aumentar a quantidade de dados de treinamento de forma sintética, e *Active learning*, que melhora a eficiência do aprendizado ao selecionar amostras mais informativas, têm sido exploradas para mitigar esses problemas. Por fim, a dependência de domínio, dada a especificidade dos textos legais, impõe a necessidade de adaptar os modelos a contextos muito particulares, o que exige uma personalização contínua dos modelos para cada subdomínio do Direito.

Agradecimentos

Gostaríamos de expressar nossa gratidão à Câmara dos Deputados Brasileira, ao Instituto de Ciências Matemáticas e de Computação da Universidade de São Paulo (ICMC/USP) e ao Instituto Nacional de Inteligência Artificial (IAIA) por possibilitarem o acesso a informações cruciais para o desenvolvimento da pesquisa, assim como a todos os colaboradores do projeto Ulysses. Além disso, agradecemos também à colaboração científica dos autores dos trabalhos citados neste capítulo, que gentilmente nos responderam com dados e recursos de suas pesquisas.

Referências

ABDIN, M. et al. **Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone.**, 2024. Disponível em: <<https://arxiv.org/abs/2404.14219>>

AEJAS, B.; BELHI, A.; BOURAS, A. **Smart Contracts Auto-generation for Supply Chain Contexts.** (F. Noël et al., Eds.) Product Lifecycle Management. PLM in Transition Times: The Place of Humans and Transformative Technologies. **Anais...** Cham: Springer Nature Switzerland, 2023.

AGNOLONI, T. et al. **Making Italian Parliamentary Records Machine-Actionable: the Construction of the ParlaMint-IT corpus.** Proceedings of the Workshop ParlaCLARIN III within the 13th Language Resources and Evaluation Conference. **Anais...** Marseille, France: European Language Resources Association, jun. 2022. Disponível em: <<https://aclanthology.org/2022.parlaclarin-1.17>>

AHA, D. W.; KIBLER, D.; ALBERT, M. K. **Instance-based learning algorithms.** **Machine Learning**, v. 6, n. 1, p. 37–66, 1 jan. 1991.

AI@META. **Llama 3 Model Card.** 2024.



AKBIK, A. et al. **Multilingual information extraction with PolyglotIE**. Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: System Demonstrations. **Anais...**2016. Disponível em: <<https://aclanthology.org/C16-2056/>>

ALBUQUERQUE, H. et al. **UlyssesNERQ: Expanding Queries from Brazilian Portuguese Legislative Documents through Named Entity Recognition**. (P. Gamallo et al., Eds.) Proceedings of the 16th International Conference on Computational Processing of Portuguese - Vol. 1. **Anais...**Santiago de Compostela, Galicia/Spain: Association for Computational Linguistics, mar. 2024. Disponível em: <<https://aclanthology.org/2024.propor-1.35>>

ALBUQUERQUE, H. O. et al. **UlyssesNER-Br: A Corpus of Brazilian Legislative Documents for Named Entity Recognition**. (V. Pinheiro et al., Eds.) Computational Processing of the Portuguese Language. **Anais...**Cham: Springer International Publishing, 2022. Disponível em: <<https://github.com/ulysses-camara/>>

ALBUQUERQUE, H. O. et al. **Named entity recognition: a survey for the portuguese language**. **Procesamiento del Lenguaje Natural**, b2023.

ALBUQUERQUE, H. O. et al. **On the Assessment of Deep Learning Models for Named Entity Recognition of Brazilian Legal Documents**. (N. Moniz et al., Eds.) Progress in Artificial Intelligence. **Anais...**Cham: Springer Nature Switzerland, a2023.

ALBUQUERQUE, H. O. et al. **UlyssesLegalNER-Br: from Legislative to Legal, a comprehensive corpus of Brazilian legal documents for Named Entity Recognition**. 17th Computational Processing of the Portuguese Language (PROPOR 2026). **Anais...**2026.

ALLES, V. J. **Construção de um corpus para extrair entidades nomeadas do Diário Oficial da União utilizando aprendizado supervisionado**. mathesis—[s.l.] Master's thesis, Universidade Federal de Brasília, 2018.

ALMEIDA, P. G. R. **Uma jornada para um Parlamento inteligente: Câmara dos Deputados do Brasil**. **Red Información**, v. 24, 2021.

ANDREW, J. J.; TANNIER, X. **Automatic Extraction of Entities and Relation from Legal Documents**. Proceedings of the Seventh Named Entities Workshop. **Anais...**Melbourne, Australia: Association for Computational Linguistics, jul. 2018.

ANGELIDIS, I.; CHALKIDIS, I.; KOUBARAKIS, M. **Named entity recognition, linking and generation for greek legislation**. Legal Knowledge and Information Systems. **Anais...**IOS Press, 2018.

ARAÚJO, P. H. L. DE et al. **LeNER-Br: A Dataset for Named Entity Recognition in Brazilian Legal Text**. (A. Villavicencio et al., Eds.) Computational Processing of the Portuguese Language. **Anais...**Cham: Springer International Publishing, 2018. Disponível em: <<https://github.com/peluz/lener-br>>



AVERINA, M.; LEVANOVA, O.; KASATKINA, N. **Named Entity Recognition for Russian Judicial Rulings Text**. 2022 32nd Conference of Open Innovations Association (FRUCT). **Anais...**2022.

BACH, N. X. et al. **Reference Extraction from Vietnamese Legal Documents**. Proceedings of the 10th International Symposium on Information and Communication Technology. **Anais...** SoICT '19. New York, NY, USA: Association for Computing Machinery, 2019.

BARRIERE, V.; FOURET, A. **May I Check Again? — A simple but efficient way to generate and use contextual dictionaries for Named Entity Recognition. Application to French Legal Texts**. Proceedings of the 22nd Nordic Conference on Computational Linguistics. **Anais...**Turku, Finland: Linköping University Electronic Press, 2019. Disponível em: <<https://aclanthology.org/W19-6136>>

BATISTA, H. H. et al. **A comparative analysis of text embedding approach to extract named entities in Portuguese legal documents**. **Anais do XVIII Encontro Nacional de Inteligência Artificial e Computacional**. **Anais...**SBC, 2021.

BONIFACIO, L. H. et al. **A Study on the Impact of Intradomain Finetuning of Deep Language Models for Legal Named Entity Recognition in Portuguese**. (R. Cerri, R. C. Prati, Eds.) **Intelligent Systems**. **Anais...**Cham: Springer International Publishing, 2020.

BONIFACIO, L. H. N. **Modelos Profundos de Linguagem para Reconhecimento de Entidades Nomeadas em Domínio Jurídico**. mathesis—[s.l.] Master's thesis, Universidade Federal de Mato Grosso do Sul, 2020.

BORDINO, I. et al. **Garnlp: a natural language processing pipeline for garnishment documents**. **Information Systems Frontiers**, v. 23, p. 101–114, 2021.

BRANDT, M. B. **Modelagem da informação legislativa: arquitetura da informação para o processo legislativo brasileiro**. tese de doutorado—[s.l.] Universidade Estadual Paulista (Unesp), 2020.

BRITO, M. et al. **CDJUR-BR - Uma Coleção Dourada do Judiciário Brasileiro com Entidades Nomeadas Refinadas**. **Anais do XIV Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana**. **Anais...**Porto Alegre, RS, Brasil: SBC, 2023. Disponível em: <<https://github.com/mauriciobritojr/CDJUR-BR>>

BROWN, T. B. et al. **Language Models are Few-Shot Learners**. (H. Larochelle et al., Eds.) **Advances in Neural Information Processing Systems**. **Anais...**Curran Associates, Inc., 2020. Disponível em: <<https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc64967418bfb8ac142f64a-Abstract.html>>

CABRERA-DIEGO, L. A.; GHEEWALA, A. **Jus Mundi at SemEval-2023 Task 6: Using a Frustratingly Easy Domain Adaption for a Legal Named Entity Recognition System**. Proceedings of the 17th International Workshop on Semantic



Evaluation (SemEval-2023). **Anais...**Toronto, Canada: Association for Computational Linguistics, jul. 2023.

CARDELLINO, C. et al. **Legal NERC with ontologies, Wikipedia and curriculum learning**. Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers. **Anais...**Valencia, Spain: Association for Computational Linguistics, abr. 2017. Disponível em: <<https://aclanthology.org/E17-2041>>

CASTRO, P. **Aprendizagem profunda para reconhecimento de entidades nomeadas em domínio jurídico**. mathesis—[s.l.] Master's thesis, Universidade Federal de Goiás, 2019.

ÇETINDAĞ, C.; YAZICIOĞLU, B.; KOÇ, A. **Named-entity recognition in Turkish legal texts**. **Natural Language Engineering**, p. 1–28, 2022.

CHALKIDIS, I. et al. **LEGAL-BERT: The Muppets straight out of Law School**. Findings of the Association for Computational Linguistics: EMNLP 2020. **Anais...**Online: Association for Computational Linguistics, nov. 2020.

CHALKIDIS, I. et al. **Regulatory Compliance through Doc2Doc Information Retrieval: A case study in EU/UK legislation where text similarity has limitations**. Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume. **Anais...**Online: Association for Computational Linguistics, abr. 2021.

CHALKIDIS, I.; ANDROUTSOPOULOS, I. **A deep learning approach to contract element extraction**. Em: **Legal knowledge and information systems**. [s.l.] IOS Press, 2017. p. 155–164.

CHALKIDIS, I.; ANDROUTSOPOULOS, I.; ALETRAS, N. **Neural Legal Judgment Prediction in English**. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. **Anais...**Association for Computational Linguistics, 2019.

CHALKIDIS, I.; ANDROUTSOPOULOS, I.; MICHOS, A. **Extracting Contract Elements**. Proceedings of the 16th Edition of the International Conference on Artificial Intelligence and Law. **Anais...** ICAIL '17. New York, NY, USA: Association for Computing Machinery, 2017.

CHEN, Y. et al. **Joint Entity and Relation Extraction for Legal Documents with Legal Feature Enhancement**. Proceedings of the 28th International Conference on Computational Linguistics. **Anais...**Barcelona, Spain (Online): International Committee on Computational Linguistics, dez. 2020.

COELHO, G. et al. **Information Extraction in the Legal Domain: Traditional Supervised Learning vs. ChatGPT**. INSTICC; SciTePress, 2024.

CORREIA, F. A. et al. **Fine-grained legal entity annotation: A case study on the Brazilian**



Supreme Court. **Information Processing & Management**, v. 59, n. 1, p. 102794, 2022.

CORTES, C.; VAPNIK, V. **Support-Vector Networks**. **Machine Learning**, v. 20, n. 3, p. 273–297, set. 1995.

COSTA, R. et al. **Expanding UlyssesNER-Br Named Entity Recognition Corpus with Informal User-Generated Text**. (G. Marreiros et al., Eds.) **Progress in Artificial Intelligence**. **Anais...**Cham: Springer International Publishing, 2022. Disponível em: <<https://github.com/ulysses-camara/>>

DALE, R.; MAZUR, P. **Handling Conjunctions in Named Entities**. (A. Gelbukh, Ed.) **Computational Linguistics and Intelligent Text Processing**. **Anais...**Berlin, Heidelberg: Springer Berlin Heidelberg, 2007.

DARJI, H.; MITROVIĆ, J.; GRANITZER, M. **German BERT Model for Legal Named Entity Recognition**. **Proceedings of the 15th International Conference on Agents and Artificial Intelligence**. **Anais...**SCITEPRESS - Science; Technology Publications, 2023.

DEVLIN, J. et al. **BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**. (J. Burstein, C. Doran, T. Solorio, Eds.) **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019**. **Anais...**Minneapolis, MN, USA: Association for Computational Linguistics, 2019. Disponível em: <<https://doi.org/10.18653/v1/n19-1423>>

DOZIER, C. et al. **Named Entity Recognition and Resolution in Legal Text**. Em: FRANCESCONI, E. et al. (Eds.). **Semantic Processing of Legal Texts: Where the Language of Law Meets the Law of Language**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010. p. 27–43.

FERNANDES, J. M.; WON, M.; MARTINS, B. **Speechmaking and the Selectorate: Persuasion in Nonpreferential Electoral Systems**. **Comparative Political Studies**, v. 53, n. 5, p. 667–699, a2020.

FERNANDES, W. P. D. et al. **Appellate court modifications extraction for Portuguese**. **Artificial Intelligence and Law**, v. 28, n. 3, p. 327–360, b2020.

FIRDAUS SOLIHIN, R. F. A., Indra Budi; MAKARIM, E. **Advancement of information extraction use in legal documents**. **International Review of Law, Computers & Technology**, v. 35, n. 3, p. 322–351, 2021.

GARCIA, E. A. S. et al. **RoBERTaLexPT: A Legal RoBERTa Model pretrained with deduplication for Portuguese**. (P. Gamallo et al., Eds.) **Proceedings of the 16th International Conference on Computational Processing of Portuguese - Vol. 1**. **Anais...**Santiago de Compostela, Galicia/Spain: Association for Computational Linguistics, mar. 2024. Disponível em: <<https://aclanthology.org/2024.propor-1.38>>



- GORMAN, K.; BEDRICK, S. **We Need to Talk about Standard Splits**. (A. Korhonen, D. Traum, L. Màrquez, Eds.) Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. **Anais...** Florence, Italy: Association for Computational Linguistics, jul. 2019. Disponível em: <<https://aclanthology.org/P19-1267/>>
- GRAVES, A.; MOHAMED, A.; HINTON, G. **Speech recognition with deep recurrent neural networks**. 2013 IEEE International Conference on Acoustics, Speech and Signal Processing. **Anais...**2013.
- GUIMARÃES, G. M. C. et al. **Legal Document Segmentation and Labeling Through Named Entity Recognition Approaches**. **Journal of Information and Data Management**, v. 15, n. 1, 2024.
- HARTMANN PEIXOTO, F. **Projeto Victor: relato do desenvolvimento da Inteligência Artificial na Repercussão Geral do Supremo Tribunal Federal**. **Revista Brasileira de Inteligência Artificial e Direito - RBIAD**, v. 1, n. 1, p. 1–22, 2020.
- HEUSDEN, R. VAN; KAMPS, J.; MARX, M. **Neural Coreference Resolution for Dutch Parliamentary Documents with the DutchParliament Dataset**. **Data**, v. 8, n. 2, 2023.
- HOCHREITER, S.; SCHMIDHUBER, J. **Long Short-Term Memory**. **Neural Computation**, v. 9, n. 8, p. 1735–1780, nov. 1997.
- HUSSAIN, A. S.; THOMAS, A. **Large Language Models for Judicial Entity Extraction: A Comparative Study**., 2024. Disponível em: <<https://arxiv.org/abs/2407.05786>>
- IFTIKHAR, A.; UL QOUNAIN JAFFRY, S. W.; MALIK, M. K. **Information Mining From Criminal Judgments of Lahore High Court**. **IEEE Access**, v. 7, p. 59539–59547, 2019.
- JIANG, A. Q. et al. **Mistral 7B**., 2023. Disponível em: <<https://arxiv.org/abs/2310.06825>>
- KAPOOR, A. et al. **HLDC: Hindi Legal Documents Corpus**. Findings of the Association for Computational Linguistics: ACL 2022. **Anais...** Association for Computational Linguistics, 2022.
- KORNILOVA, A.; EIDELMAN, V. **BillSum: A Corpus for Automatic Summarization of US Legislation**. Proceedings of the 2nd Workshop on New Frontiers in Summarization. **Anais...** Association for Computational Linguistics, 2019.
- KULKARNI, M. et al. **Towards a Unified Multi-Domain Multilingual Named Entity Recognition Model**. Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics. **Anais...** Dubrovnik, Croatia: Association for Computational Linguistics, 2023. Disponível em: <<https://aclanthology.org/2023.eacl-main.161>>
- LAFFERTY, J. D.; MCCALLUM, A.; PEREIRA, F. C. N. **Conditional Random**



Fields: Probabilistic Models for Segmenting and Labeling Sequence Data. Proceedings of the Eighteenth International Conference on Machine Learning. **Anais...**: ICML '01. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2001. Disponível em: <<https://dl.acm.org/doi/abs/10.5555/645530.655813>>

LAMPLE, G. et al. **Neural Architectures for Named Entity Recognition.** (K. Knight, A. Nenkova, O. Rambow, Eds.) Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. **Anais...** San Diego, California: Association for Computational Linguistics, jun. 2016.

LEITNER, E.; REHM, G.; MORENO-SCHNEIDER, J. **Fine-Grained Named Entity Recognition in Legal Documents.** (M. Acosta et al., Eds.) Semantic Systems. The Power of AI and Knowledge Graphs. **Anais...** Cham: Springer International Publishing, 2019.

LIMA, A. DA S.; BORGES, V. R. **Training and evaluating Named Entity Recognition Models using a Legal Corpus of publications from Government Gazettes.** 2022.

LIU, Y. et al. **RoBERTa: A Robustly Optimized BERT Pretraining Approach.**, 2019. Disponível em: <<https://arxiv.org/abs/1907.11692>>

LORÈ, F. et al. **An AI framework to support decisions on GDPR compliance.** **Journal of Intelligent Information Systems**, p. 1–28, 2023.

MAIA, D. F. et al. **UlyssesSD-Br: Stance Detection in Brazilian Political Polls.** (G. Marreiros et al., Eds.) Progress in Artificial Intelligence. **Anais...** Cham: Springer International Publishing, 2022. Disponível em: <<https://github.com/Dyonnatan/UlyssesSD-Br>>

MALIK, V. et al. **ILDC for CJPE: Indian Legal Documents Corpus for Court Judgment Prediction and Explanation.** Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). **Anais...** Association for Computational Linguistics, 2021.

MALOUF, R. **A Comparison of Algorithms for Maximum Entropy Parameter Estimation.** COLING-02: The 6th Conference on Natural Language Learning 2002 (CoNLL-2002). **Anais...** 2002. Disponível em: <<https://aclanthology.org/W02-2018>>

MAXWELL, K. T.; SCHAFER, B. **Concept and context in legal information retrieval.** Em: **Legal Knowledge and Information Systems.** [s.l.] IOS Press, 2008. p. 63–72.

MORENO SCHNEIDER, J. et al. **Lynx: A knowledge-based AI service platform for content processing, enrichment and analysis for the legal domain.** **Information Systems**, v. 106, p. 101966, 2022.

MOTA, C. C. et al. **Reconhecimento de entidades nomeadas em documentos**



jurídicos em português utilizando redes neurais. Encontro Nacional de Inteligência Artificial e Computacional (ENIAC). **Anais...**SBC, 2021.

NETO, J. R. C. S. A. V. S.; FALEIROS, T. DE P. **Deep Active-Self Learning Applied to Named Entity Recognition.** (A. Britto, K. Valdivia Delgado, Eds.) Intelligent Systems. **Anais...**Cham: Springer International Publishing, 2021. Disponível em: <<https://avio11.github.io/resources/aposentadoria/aposentadoria.html>>

NOGUEIRA, R. et al. Document expansion by query prediction. **arXiv preprint arXiv:1904.08375**, 2019.

NUNES, R. O. et al. **Out of Sesame Street: A Study of Portuguese Legal Named Entity Recognition Through In-Context Learning.** INSTICC; SciTePress, a2024.

NUNES, R. O. et al. **A Named Entity Recognition Approach for Portuguese Legislative Texts Using Self-Learning.** (P. Gamallo et al., Eds.) Proceedings of the 16th International Conference on Computational Processing of Portuguese - Vol. 1. **Anais...**Santiago de Compostela, Galicia/Spain: Association for Computational Linguistics, mar. b2024. Disponível em: <<https://aclanthology.org/2024.propor-1.30>>

NUNES, R. O. **Data contamination in specialized named entity recognition corpora.** Dissertação de Mestrado—Porto Alegre, Brasil: Universidade Federal do Rio Grande do Sul, 2025.

OKSANEN, A. et al. **Semantic Finlex: Transforming, Publishing, and Using Finnish Legislation and Case Law As Linked Open Data on the Web.** Em: PERUGINELLI, G.; FARO, S. (Eds.). **Knowledge of the Law in the Big Data Age.** Frontiers em Artificial Intelligence e Applications. [s.l.] IOS Press, 2019b. v. 317p. 212–228.

OKSANEN, A. et al. **ANOPPI: A Pseudonymization Service for Finnish Court Documents.** JURIX. **Anais...**a2019.

OKSANEN, A. et al. **An Anonymization Tool for Open Data Publication of Legal Documents.** Joint Proceedings of ISWC2022 Workshops. **Anais...**CEUR-WS. org, 2022. Disponível em: <<https://ceur-ws.org/Vol-3257/>>

OLIVEIRA, V. et al. **Combining prompt-based language models and weak supervision for labeling named entity recognition on legal documents.** **Artificial Intelligence and Law**, p. 1–21, fev. 2024.

ONAGA, T.; FUJITA, M.; YOSHINOBU, K. **Japanese Legal Bar Problem Solver Focusing on Person Names.** Proceedings of the Tenth International Competition on Legal Information Extraction/Entailment (COLIEE 2023). **Anais...**2023. Disponível em: <<https://sites.ualberta.ca/~rabelo/COLIEE2023>>

PAIS, V. et al. **Named Entity Recognition in the Romanian Legal Domain.** Proceedings of the Natural Legal Language Processing Workshop 2021. **Anais...**Punta Cana, Dominican Republic: Association for Computational Linguistics, nov. 2021.



- PAIS, V. et al. **LegalNERo: A linked corpus for named entity recognition in the Romanian legal domain**. *Semantic Web journal*, 2024.
- PENNINGTON, J.; SOCHER, R.; MANNING, C. **GloVe: Global Vectors for Word Representation**. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). *Anais...*Doha, Qatar: Association for Computational Linguistics, out. 2014. Disponível em: <<https://aclanthology.org/D14-1162>>
- PETERS, M. E. et al. **Deep Contextualized Word Representations**. (M. A. Walker, H. Ji, A. Stent, Eds.)Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2018, New Orleans, Louisiana, USA, June 1-6, 2018, Volume 1 (Long Papers). *Anais...*Association for Computational Linguistics, 2018. Disponível em: <<https://doi.org/10.18653/v1/n18-1202>>
- PILÁN, I. et al. The text anonymization benchmark (tab): A dedicated corpus and evaluation framework for text anonymization. *Computational Linguistics*, v. 48, n. 4, p. 1053–1101, 2022.
- PIRES, R. et al. **Sabiá: Portuguese Large Language Models**. (M. C. Naldi, R. A. C. Bianchi, Eds.)Intelligent Systems. *Anais...*Cham: Springer Nature Switzerland, 2023.
- PIROVANI, J. P. C. **CRF+ LG: uma abordagem híbrida para o reconhecimento de entidades nomeadas em português**. tese de doutorado—[s.l.] Universidade Federal do Espírito Santo, Vitória (Brasil), 2019.
- POLO, F. M. et al. **LegalNLP – Natural Language Processing methods for the Brazilian Legal Language.**, 2021. Disponível em: <<https://arxiv.org/abs/2110.15709>>
- QUARESMA, P.; GONÇALVES, T. **Using Linguistic Information and Machine Learning Techniques to Identify Entities from Juridical Documents**. Em: FRANCESCONI, E. et al. (Eds.). **Semantic Processing of Legal Texts: Where the Language of Law Meets the Law of Language**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010. p. 44–59.
- RODRIGUEZ, M. M.; BEZERRA, B. L. D. **Processamento de linguagem natural para reconhecimento de entidades nomeadas em textos jurídicos de atos administrativos (portarias)**. *Revista de Engenharia e Pesquisa Aplicada*, v. 5, n. 1, p. 67–77, 2020.
- SAINZ, O. et al. NLP Evaluation in trouble: On the Need to Measure LLM Data Contamination for each Benchmark. **Findings of the Association for Computational Linguistics: EMNLP 2023**, 2023.
- SAMY, D. **Reconocimiento y clasificación de entidades nombradas en textos legales en español**. *Procesamiento del lenguaje natural*, v. 67, p. 103–114, 2021.
- SANG, E. F. T. K.; DE MEULDER, F. **Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition**. Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003. *Anais...*2003.



Disponível em: <<https://aclanthology.org/W03-0419>>

SANSONE, C.; SPERLÍ, G. **Legal Information Retrieval systems: State-of-the-art and open issues**. **Information Systems**, v. 106, p. 101967, 2022.

SANTOS, D.; CARDOSO, N. **A golden resource for named entity recognition in portuguese**. Proceeding of the 7th International conference on the computational processing of portuguese. **Anais...Springer**, 2007.

SCHRAAGEN, M. et al. **Evaluation of Named Entity Recognition in Dutch online criminal complaints**. **Computational Linguistics in the Netherlands Journal**, v. 7, p. 3–16, 2017.

SCHUSTER, M.; PALIWAL, K. K. **Bidirectional recurrent neural networks**. **IEEE transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHAMMA, S. A. et al. **Information Extraction from Arabic Law Documents**. 2020 IEEE 14th International Conference on Application of Information and Communication Technologies (AICT). **Anais...2020**.

SILVA, N. F. F. DA et al. **Evaluating Topic Models in Portuguese Political Comments About Bills from Brazil's Chamber of Deputies**. (A. Britto, K. Valdivia Delgado, Eds.)Intelligent Systems. **Anais...Cham: Springer International Publishing**, 2021.

SIQUEIRA, F. et al. **Ulysses Tesemô: a new large corpus for Brazilian legal and governmental domain**. **Language Resources and Evaluation**, p. 1–20, jul. 2024.

SLEIMI, A. et al. **An automated framework for the extraction of semantic legal metadata from legal texts**. **Empirical Software Engineering**, v. 26, p. 1–50, 2021.

SMYWIŃSKI-POHL, A. et al. **Automatic Extraction of Amendments from Polish Statutory Law**. Proceedings of the Eighteenth International Conference on Artificial Intelligence and Law. **Anais...: ICAIL '21**.New York, NY, USA: Association for Computing Machinery, 2021.

SOUZA, E. et al. **An Information Retrieval Pipeline for Legislative Documents from the Brazilian Chamber of Deputies**. Em: **Legal Knowledge and Information Systems**. [s.l.] IOS Press, 2021. p. 119–126.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. **BERTimbau: pretrained BERT models for Brazilian Portuguese**. (R. Cerri, R. C. Prati, Eds.)Proceedings of the 2020 Brazilian Conference on Intelligent Systems. **Anais...Springer International Publishing**, 2020.

SUTSKEVER, I.; VINYALS, O.; LE, Q. V. **Sequence to Sequence Learning with Neural Networks**. (Z. Ghahramani et al., Eds.)Advances in Neural Information Processing Systems 27: Annual Conference on Neural Information Processing Systems 2014, December 8-13 2014, Montreal, Quebec, Canada. **Anais...2014**. Disponível em: <<https://proceedings.neurips.cc/paper/2014/hash/a14ac55a4f27472c5d894ec1c3c743d2-Abstract.html>>



TEAM, G. et al. **Gemma: Open Models Based on Gemini Research and Technology.**, 2024. Disponível em: <<https://arxiv.org/abs/2403.08295>>

TOLLES, J.; MEURER, W. J. **Logistic Regression: Relating Patient Characteristics to Outcomes.** *JAMA*, v. 316, n. 5, p. 533–534, ago. 2016.

VITÓRIO, D. et al. **Ulysses-RFSQ: A Novel Method to Improve Legal Information Retrieval Based on Relevance Feedback.** (J. C. Xavier-Junior, R. A. Rios, Eds.) *Intelligent Systems. Anais...* Cham: Springer International Publishing, 2022.

VITÓRIO, D. et al. **Building a relevance feedback corpus for legal information retrieval in the real-case scenario of the Brazilian Chamber of Deputies.** *Language Resources and Evaluation*, 2024.

WANG, S. et al. **Want To Reduce Labeling Cost? GPT-3 Can Help.** (M.-F. Moens et al., Eds.) *Findings of the Association for Computational Linguistics: EMNLP 2021. Anais...* Punta Cana, Dominican Republic: Association for Computational Linguistics, nov. 2021.

WANG, S. et al. **GPT-NER: Named Entity Recognition via Large Language Models.**, 2023. Disponível em: <<https://arxiv.org/abs/2304.10428>>

WEI, X. et al. **ChatIE: Zero-Shot Information Extraction via Chatting with ChatGPT.**, 2024. Disponível em: <<https://arxiv.org/abs/2302.10205>>

ZANUZ, L.; RIGO, S. J. **Fostering Judiciary Applications with New Fine-Tuned Models for Legal Named Entity Recognition in Portuguese.** (V. Pinheiro et al., Eds.) *Computational Processing of the Portuguese Language. Anais...* Cham: Springer International Publishing, 2022.

ZHONG, H. et al. **How Does NLP Benefit Legal System: A Summary of Legal Artificial Intelligence.** *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Anais...* Association for Computational Linguistics, 2020.



Capítulo 14

Geração Automática de Ementas Jurídicas

*Kenzo Sakiyama
Roseval Malaquias Junior
Raphael Montanari
Rodrigo Nogueira
Roseli A. F. Romero*

Publicado em: 20/11/2024

 <https://brasileiraspln.ufscar.br/livro-pln-4ed-vol3/>

14.1 Introdução

14.1.1 Contextualização

Segundo dados do Conselho Nacional de Justiça (CNJ) (Justiça - CNJ, 24DC), ao final de 2022, havia 81,4 milhões de processos em trânsito no judiciário brasileiro, um aumento de 7,5% em relação ao ano anterior. O relatório também destaca que, nos casos mais extremos, o tempo de análise pode levar vários anos. Além do esforço humano necessário para a análise e elaboração dos documentos, é preciso alocar recursos financeiros para sua manutenção ao longo de todo o processo. Neste cenário, o aprimoramento de sistemas computacionais jurídicos, com a automação do fluxo de documentos, torna-se essencial para agilizar a tramitação no judiciário brasileiro.

Quadro 14.1: Exemplo de ementa. A verbetização está destacada em negrito.

DIREITO CONSTITUCIONAL, TRIBUTÁRIO, PREVIDENCIÁRIO E PROCESSUAL CIVIL. CONTRIBUIÇÃO SOCIAL. ART. 2º DA LEI Nº 7.856, DE 25 DE OUTUBRO DE 1989. MAJORAÇÃO DE 8% PARA 10%, DA ALÍQUOTA DA CONTRIBUIÇÃO SOCIAL. SUCUMBÊNCIA. HONORÁRIOS ADVOCATÍCIOS. CUSTAS PROCESSUAIS.

1. Firmou-se em Plenário do Supremo Tribunal Federal o entendimento no sentido de que, em se tratando de “lei de conversão da Medida Provisória nº 86, de 25 de setembro de 1989, da data da edição desta é que flui o prazo de noventa dias previsto no art. 195, § 6º, da CF, o qual, no caso, teve por termo final o dia 24 de dezembro do mesmo ano, possibilitando o cálculo do tributo, pela nova alíquota, sobre o lucro da recorrente, apurado no balanço do próprio exercício de 1989” (RE 197.790-6-MG, Rel. Min. ILMAR GALVÃO).
2. Adotados os fundamentos desse precedente, o RE, no caso, é conhecido e provido.
3. As autoras ficaram vencedoras, quanto a outros pedidos, nas instâncias ordinárias, sem que o R.E. abordasse esses pontos. Sendo maior a sucumbência da ré, pagará honorários advocatícios às autoras.
4. Custas em proporção.

Este Capítulo trata da geração automática de **ementas**, documentos amplamente utilizados em tribunais brasileiros, cuja função é fornecer um resumo de processos judiciais. As ementas oferecem uma representação sucinta e simplificada das decisões, permitindo



que profissionais do Direito compreendam rapidamente o conteúdo sem a necessidade de ler o acórdão completo. Conforme demonstra o exemplo no Quadro 14.1, estes documentos usualmente contêm dois elementos principais: **verbetações** e **parágrafos enumerados**.

As **verbetações** são cabeçalhos constituídos por frases curtas, em caixa-alta, que descrevem os assuntos mais relevantes da decisão. Além de resumir o conteúdo, elas auxiliam na tarefa de busca e recuperação de jurisprudências (precedentes) (Guimarães; Santos, 2016). Por outro lado, os **parágrafos enumerados** expõem as teses da decisão, sendo que o último apresenta geralmente a conclusão do tribunal. Essa estrutura contribui para a agilidade no acesso à informação jurídica, facilitando a consulta à jurisprudência.

Vale destacar que, devido à sua estrutura e estilo, as verbetações assemelham-se a palavras-chave e a textos sumarizados. No entanto, diferentemente das palavras-chave, elas podem consistir em frases curtas. Além disto, enquanto resumos são redigidos de maneira fluida, as verbetações seguem um estilo linguístico único e rígido em comparação aos resumos. Um desafio adicional na redação das verbetações é que muitos dos termos utilizados não aparecem no restante da ementa, tornando sua produção uma tarefa que vai além da simples extração de informação.

Considerando as características do sistema judiciário brasileiro, os componentes das ementas e sua grande disponibilidade no Brasil, o objetivo deste Capítulo é apresentar métodos de PLN que propiciam a automatização da escrita de verbetações empregando os parágrafos enumerados como entradas para um modelo supervisionado generativo. Em específico, como Transformers (Brown et al., 2020c; Carmo et al., 2020b; Scao et al., 2022; Zhang et al., 2022) se mostraram efetivos em tarefas de geração de texto, neste capítulo os mesmos são avaliados na tarefa de geração de verbetações. O Quadro 14.2 ilustra exemplos de verbetações geradas por Transformers, nos quais fica evidente a capacidade desse modelo generativo, obtendo resultados semelhantes à verbetações escritas por especialistas.

Quadro 14.2: Exemplos de verbetações geradas por Transformers.

Original: PROCESSUAL CIVIL. EMBARGOS DE DECLARAÇÃO NO RECURSO ESPECIAL. ALEGAÇÃO DE OMISSÃO. RESSALVAS DE FUNDAMENTAÇÃO CONTIDAS NO VOTO-VISTA. OMISSÃO NÃO CARACTERIZADA.

Gerada: PROCESSUAL CIVIL. EMBARGOS DE DECLARAÇÃO. OMISSÃO. VÍCIO INEXISTENTE. REJEIÇÃO.

Original: AGRAVO REGIMENTAL NO HABEAS CORPUS. TRÁFICO DE DROGAS. PRISÃO PREVENTIVA. PERICULUM LIBERTATIS. CRISE MUNDIAL DE COVID-19. NÃO DEMONSTRADA A EXISTÊNCIA DE RISCO À INTEGRIDADE FÍSICA DO ENCARCERADO. AGRAVO REGIMENTAL NÃO PROVIDO.

Gerada: AGRAVO REGIMENTAL NO HABEAS CORPUS. TRÁFICO DE DROGAS. PRISÃO PREVENTIVA. PERICULUM LIBERTATIS. AGRAVO REGIMENTAL NÃO PROVIDO.

Este Capítulo apresenta mais uma aplicação de PLN na área do Direito, assim como as apresentadas no Capítulo **PLN no Direito**. São utilizados modelos de linguagem (descritos no Capítulo **Modelos de linguagem**) em uma tarefa de geração de texto, similar à tarefa de sumarização (Capítulo **Sumarização Automática**). A metodologia proposta descreve como a coleta de dados foi realizada, apresenta o modelo transformer utilizado e também a técnica de validação e métrica adotadas. Além disto, emprega-se conceitos de Recuperação de Informação (Capítulo **Recuperação de Informação**) para avaliação final das verbetações geradas.

